Datadriven analys av handläggningstid i ärendehantering



Lence Majzovska

EC Utbildning

Examensarbete

2026/10

Abstract

This study analyzes handling time in a case management process with the aim of identifying factors associated with process efficiency and examining whether handling time can be predicted using structured process data. The analysis is based on historical, resolved cases from a public incident management dataset and combines exploratory analysis with machine learning. The results show that a small number of long-running cases strongly affect handling time, and that a higher number of reassignments is associated with longer handling time. The prediction models achieve only limited accuracy, which suggests that the available data explains only part of the variation. Overall, the study demonstrates both the potential and the limitations of using process data to analyze and predict handling time.

Innehållsförteckning

1 Inledning 1

2 Teori 2

2.1 Regressionsproblem 2

2.2 Explorativ dataanalys 2

2.3 Maskininlärning och prediktiv modellering 2

2.4 Förbehandling av data 3

2.4.1 Target leakage 3

2.4.2 Multikollinearitet 3

2.4.3 Hantering av kategoriska variabler 3

2.5 Modelloptimering 4

2.5.1 Log-transformering 4

2.5.2 Hyperparameteroptimering 4

2.6 Modellutvärdering 4

2.7 Modelltolkning med SHAP 5

2.8 Begränsningar i data och modellering 5

3 Metod 6

3.1 Data och förberedelse 6

3.2 Explorativ analys och datatransformering 6

3.3 Modellering 7

3.3.1 Modellval och datauppdelning 7

3.3.2 Hantering av target leakage 7

3.3.3 Log-transformering av målvariabeln 8

3.3.4 Hyperparameteroptimering 8

3.3.5 Pipeline och tester 8

3.4 Modellutvärdering 8

4 Resultat och diskussion 9

4.1 KPI- och processanalys 9

4.2 Övergripande analys av handläggningstid 9

4.3 Processrelaterade faktorer 10

4.4 Initial modellering 11

4.5 Log-transformering och hyperparameteroptimering 12

4.6 SHAP-analys och variabelbetydelse 13

4.7 Residualanalys 14

5 Slutsatser & Lärdomar 15

5.1 Datans betydelse 15
5.2 Modellens praktiska användbarhet 15
5.3 Sammanfattande reflektion 15
6 Framtida arbete 16
Appendix A 17
A.1 Modellkonfiguration 17
A.2 Log-transformering 18
A.3 Hyperparameteroptimering 19
A.4 Projektlänkar 19
Källförteckning 20

1 Inledning

Ärendehantering är en central del i många verksamheter där effektivitet och kvalitet i handläggningsprocesser har stor betydelse för både kundnöjdhet och resursanvändning. En viktig aspekt i detta sammanhang är handläggningstid, det vill säga hur lång tid det tar att hantera och avsluta ett ärende.

Trots att handläggningstid är en viktig indikator är det ofta oklart vilka faktorer som faktiskt påverkar hur lång tid ett ärende tar att hantera. Variationer kan bero på flera olika omständigheter och dessa fångas inte alltid i tillgänglig data.

Genom att analysera data från ärendehanteringssystem finns möjlighet att undersöka samband mellan olika processrelaterade variabler och handläggningstid. Samtidigt väcks frågan om handläggningstid kan predikteras med hjälp av strukturerad processdata, eller om variationen främst drivs av faktorer som inte registreras i systemen.

Detta projekt syftar till att analysera handläggningstid med hjälp av explorativ dataanalys och prediktiv modellering. Fokus ligger på att undersöka samband mellan handläggningstid och faktorer såsom prioritet, processaktivitet, omfördelningar, återöppnade ärenden och SLA-uppfyllelse samt att analysera modellernas förmåga att identifiera mönster i datan.

Analysen baseras på ett publikt dataset med anonymiserad loggdata från ett verkligt ärendehanteringssystem (ServiceNow). Resultaten används för att belysa möjliga mönster, processrelaterade ineffektiviteter och begränsningar i vad som kan förklaras med hjälp av tillgängliga variabler.

Frågeställningar:

1. Vilka faktorer är kopplade till längre handläggningstid i en ärendehanteringsprocess?
2. Kan handläggningstid predikteras med hjälp av tillgängliga processvariabler?
3. Vilka begränsningar finns i att använda strukturerad processdata för att förklara och prediktera handläggningstid?

2 Teori

Detta kapitel presenterar teoretiska grunder inom dataanalys och prediktiv modellering med fokus på handläggningstid i ärendehantering. Centrala områden inkluderar explorativ dataanalys, regressionsanalys, maskininlärning, förbehandling av data, modelloptimering, modellutvärdering samt modelltolkning.

Handläggningstid är en viktig indikator inom verksamhets- och processanalys eftersom den kan användas för att identifiera ineffektiviteter, resurskrävande processer och variationer i ärendehantering.

Till skillnad från klassificeringsproblem, där målet är att förutsäga diskreta utfall, behandlas handläggningstid som en kontinuerlig variabel. Problemet formuleras därför som ett regressionsproblem.

2.1 Regressionsproblem

Inom maskininlärning innebär ett regressionsproblem att en modell tränas för att förutsäga ett kontinuerligt numeriskt värde baserat på en uppsättning förklarande variabler. Regressionsproblem skiljer sig från klassificering genom att utfallet representerar ett värde på en kontinuerlig skala snarare än en fördefinierad klass, vilket ställer krav på andra typer av modeller och utvärderingsmått.

I detta projekt används regressionsmodeller för att analysera och prediktera handläggningstid baserat på processrelaterade variabler såsom prioritet, omfördelningar, återöppnade ärenden, tilldelad handläggargrupp samt ärendekategori.

2.2 Explorativ dataanalys

Explorativ dataanalys (EDA) är ett viktigt steg i analysprocessen där data undersöks genom visualisering och sammanfattande statistik. Syftet är att identifiera mönster, variationer och avvikelser i datan samt att skapa en grundläggande förståelse för hur olika variabler relaterar till varandra.

I kontexten av ärendehantering används EDA för att analysera hur handläggningstid varierar mellan olika processrelaterade faktorer. Genom att undersöka samband mellan exempelvis prioritet, processaktivitet, omfördelningar och SLA-uppfyllelse (Service Level Agreement, ett avtalat mål för hur snabbt ett ärende ska lösas) kan analysen ge en bättre förståelse för vilka faktorer som är kopplade till längre handläggningstider och variationer i processen. EDA används även för att identifiera möjliga mönster och samband som senare kan undersökas vidare genom prediktiv modellering.

2.3 Maskininlärning och prediktiv modellering

Maskininlärning (ML) används för att identifiera mönster i data och skapa modeller som kan användas för prediktion. I detta projekt används *supervised learning*, där modeller tränas på historisk data med kända utfall (handläggningstid) för att kunna förutsäga nya observationer (Géron, 2019).

Fyra typer av modeller används:

- Naiv baseline är en enkel referensmodell som alltid predikterar ett konstant värde (till exempel medianen av handläggningstid), oavsett indata. Den används för att avgöra om de tränade modellerna faktiskt tillför prediktivt värde utöver ett enkelt antagande.
- Linjär regression är den enklaste av de tränade modellerna och antar ett linjärt samband mellan variabler. Den ger en indikation på om mer avancerade, icke-linjära modeller tillför ytterligare prediktivt värde.
- Random Forest är en trädbaserad ensemblemetod som kan fånga mer komplexa och icke-linjära samband genom att kombinera flera beslutsträd.
- Gradient Boosting är en ensemblemetod där flera enkla modeller successivt kombineras för att förbättra prediktionsförmågan och fånga komplexa mönster i datan.

En central utmaning inom maskininlärning är att balansera modellens komplexitet. Modeller som är för enkla kan missa viktiga samband, medan alltför komplexa modeller kan överanpassa träningsdatan och prestera sämre på ny data.

2.4 Förbehandling av data

Innan en modell kan tränas behöver datan förberedas så att den är lämplig för modellering. Det innebär bland annat att avgöra vilka variabler som får användas och att omvandla variablerna till ett format som modellerna kan hantera. Följande avsnitt beskriver tre begrepp som är centrala i detta arbete: *target leakage*, multikollinearitet och hantering av kategoriska variabler.

2.4.1 Target leakage

Target leakage uppstår när en förklarande variabel innehåller information som inte är känd vid tidpunkten för prediktion, utan uppstår som en konsekvens av det som ska förutsägas. Modeller som tränas med sådana variabler kan uppvisa ett orimligt gott resultat som inte går att uppnå i praktiken. Det är därför viktigt att kontrollera att alla förklarande variabler rimligen är tillgängliga när prediktionen ska göras.

2.4.2 Multikollinearitet

Multikollinearitet uppstår när två eller flera förklarande variabler är starkt relaterade till varandra, så att de i praktiken innehåller samma information. Det kan göra det svårt att avgöra vilken variabel som bidrar till modellens prediktioner, och särskilt för linjära modeller kan det ge instabila resultat. Om en variabel helt bestäms av andra variabler tillför den ingen ny information och kan därför uteslutas.

2.4.3 Hantering av kategoriska variabler

Kategoriska variabler, som prioritet och tilldelad grupp, består av kategorier och inte av numeriska värden, och måste därför omvandlas innan de kan användas i en modell. En vanlig metod är *one-hot encoding*, där en ny variabel skapas för varje kategori. Variabeln är 1 om ärendet tillhör kategorin och 0 annars.

Om en variabel har många olika kategorier blir antalet nya variabler stort, vilket kan göra modellen onödigt komplex. Ett vanligt sätt att hantera det är att behålla de vanligaste kategorierna och samla resterande under en gemensam kategori.

Förbehandling och modellträning kan kombineras i en pipeline, där stegen utförs i en bestämd ordning. Vid korsvalidering anpassas förbehandlingen enbart på träningsdelen i varje delning och tillämpas därefter på valideringsdelen. Detta minskar risken för att information från valideringsdelen påverkar modellträningen.

2.5 Modelloptimering

Efter att datan har förberetts kan modellens prestanda förbättras ytterligare. Det kan göras på flera sätt, bland annat genom att transformera målvariabeln så att den får en fördelning som modellerna hanterar bättre, och genom att justera de inställningar som styr hur modellen tränas. Följande avsnitt beskriver dessa två metoder: log-transformering och hyperparameteroptimering.

2.5.1 Log-transformering

Log-transformering används för att hantera variabler med skev fördelning, där ett fåtal mycket höga värden påverkar modellen oproportionerligt. Genom att transformera variabeln blir fördelningen mer symmetrisk, och modellens prediktioner räknas därefter tillbaka till ursprunglig skala.

2.5.2 Hyperparameteroptimering

Hyperparameteroptimering innebär systematisk justering av de inställningar som styr hur modellen tränas, exempelvis antal beslutsträd eller inlärningstakt. Dessa inställningar bestäms inte av modellen själv under träning, utan måste väljas i förväg.

En vanlig metod är *GridSearchCV*, som uttömmande testar samtliga kombinationer av fördefinierade parametervärden. Ett alternativ är *RandomizedSearchCV*, som i stället slumpmässigt testar ett urval av möjliga kombinationer (Pedregosa et al., 2011), vilket ofta ger ett nästan likvärdigt resultat till en betydligt lägre beräkningskostnad (Bergstra & Bengio, 2012).

2.6 Modellutvärdering

För att utvärdera modellernas prestanda används flera metoder och mått:

MAE (Mean Absolute Error) mäter det genomsnittliga absoluta felet mellan modellens prediktioner och de faktiska värdena. Måttet är lätt att tolka eftersom det anges i samma enhet som målvariabeln (dagar).

R^2 (förklaringsgrad) anger hur stor del av variationen i den beroende variabeln som modellen kan förklara. Ett värde nära 1 indikerar hög förklaringsgrad, medan ett värde nära eller under 0 tyder på låg prediktiv förmåga.

Korsvalidering används för att minska beroendet av en specifik uppdelning av datan. Genom att dela upp datan i flera delar och träna och testa modellen upprepade gånger ges en mer tillförlitlig bild av modellens generaliseringsförmåga (Géron, 2019).

Vid modellval används korsvalidering på träningsdatan i stället för en separat valideringsmängd. Testdatan används först när modellen är vald, och bara en gång, så att den ger en oberoende bild av hur väl modellen presterar på ny data (Géron, 2019).

Dessa metoder kompletterar varandra genom att både ge en konkret bild av modellens fel, en övergripande bedömning av förklaringsförmågan och en indikation på resultatens stabilitet.

2.7 Modelltolkning med SHAP

För att tolka modellernas prediktioner används SHAP (SHapley Additive exPlanations), en metod som beräknar varje variabels bidrag till enskilda prediktioner (Lundberg & Lee, 2017).

Till skillnad från traditionell *feature importance* (ett modellbaserat mått på variablernas relativa betydelse) ger SHAP en mer nyanserad bild av variablernas påverkan och riktning, vilket möjliggör en djupare förståelse för vilka faktorer som driver modellens prediktioner.

2.8 Begränsningar i data och modellering

En viktig aspekt inom prediktiv analys är att modellens prestanda i hög grad påverkas av datans kvalitet och innehåll. Om relevanta variabler saknas kan även avancerade modeller uppvisa begränsad prediktionsförmåga.

I ärendehantering påverkas handläggningstid ofta av faktorer som inte finns representerade i strukturerad data, exempelvis ärendets komplexitet, arbetsbelastning och individuella handläggningsskillnader. Detta innebär att även om modeller kan identifiera vissa mönster och samband, kan deras förmåga att fullt ut förklara variationen i handläggningstid vara begränsad. Analysen bör därför tolkas med hänsyn till datans begränsningar.

3 Metod

Detta kapitel beskriver hur analysen har genomförts, från datainsamling och databearbetning till explorativ analys och prediktiv modellering. Syftet är att tillämpa en systematisk analysprocess för att undersöka handläggningstid och faktorer kopplade till variationer i processen.

3.1 Data och förberedelse

Analysen baseras på ett publikt incident management-dataset extraherat från ServiceNow och tillgängliggjort via Kaggle (Shamiul Islam Shifat, n.d.). Datan innehåller loggdata över hela ärendehanteringsprocessen, från registrering till avslut, och är anonymiserad. Datasetet omfattar bland annat information om prioritet, omfördelningar, processaktivitet, SLA-relaterad information och tidsstämplar för olika steg i processen.

Databearbetning genomfördes för att säkerställa datakvalitet och en enhetlig struktur. Kolumnnamn standardiserades och tidsvariabler konverterades till *datetime*-format.

Eftersom datasetet innehåller flera observationer per ärende sorterades händelserna i tidsordning och aggregerades till ärendenivå för att möjliggöra analys av handläggningstid. Handläggningstid beräknades utifrån skillnaden mellan öppningsdatum och lösningsdatum. Ärenden som saknade ett registrerat lösningsdatum exkluderades (1 556 av 24 918 ärenden), eftersom handläggningstid inte kunde beräknas för dessa, vilket resulterade i 23 362 ärenden för vidare analys.

Vidare skapades nya variabler kopplade till processaktivitet och återöppnade ärenden för att möjliggöra vidare analys och modellering. Variabeln **sys_mod_count** (kopplad till processaktivitet) och variabeln **made_sla** (SLA-uppfyllelse) exkluderades från den prediktiva modelleringen, eftersom de identifierades som källor till *target leakage* (se avsnitt 3.3.2). Även **impact** och **urgency** exkluderades, eftersom de tillsammans entydigt bestämde **priority** och därför inte tillförde någon ny information.

Utöver de ursprungliga variablerna inkluderades **assignment_group**, **category**, **subcategory** och **contact_type** i den slutliga modelleringen. De tre förstnämnda grupperades till de tio mest förekommande värdena, med resterande värden sammanförda till kategorin "Other".

3.2 Explorativ analys och datatransformering

Explorativ dataanalys genomfördes för att undersöka hur handläggningstid varierar mellan olika processrelaterade faktorer, såsom prioritet, processaktivitet, omfördelningar och SLA-uppfyllelse. Visualiseringar och sammanfattande statistik användes för att identifiera mönster, variationer och avvikelser i datan.

Analysen inkluderade även sammanställningar av centrala nyckeltal för att ge en övergripande bild av processens effektivitet, exempelvis genomsnittlig handläggningstid, SLA-uppfyllelse och andel återöppnade ärenden.

För att förbereda datan för modellering transformerades kategoriska variabler med hjälp av *one-hot encoding*, där varje kategori omvandlades till en egen binär kolumn. Den beroende variabeln definierades som handläggningstid i dagar, medan ett urval av processrelaterade variabler användes som förklarande variabler.

3.3 Modellering

För att undersöka om handläggningstid kan predikteras användes regressionsmodeller med olika grad av komplexitet: linjär regression, Random Forest och Gradient Boosting. Som referenspunkt inkluderades även en naiv baseline-modell som alltid predikterar medianvärdet av handläggningstid.

Modelleringen syftade både till att undersöka modellernas förmåga att prediktera handläggningstid och till att identifiera vilka variabler som hade störst betydelse för variationer i handläggningstid.

3.3.1 Modellval och datauppdelning

Modellerna implementerades i Python med biblioteket scikit-learn (Pedregosa et al., 2011). Datan delades upp i tränings- och testdata (80/20). Ett fast slumptal (random_state=42) användes för uppdelningen och modellerna, så att resultaten kan återskapas. Modellerna jämfördes och valdes med korsvalidering på träningsdatan, medan testdatan sparades för en slutlig utvärdering av den valda modellen.

Förbehandlingen, det vill säga grupperingen och kodningen av kategoriska variabler, ingick tillsammans med modellen i en pipeline i scikit-learn. Förbehandlingen anpassades därmed enbart på träningsdelen i varje korsvalideringsdelning, utan att information från valideringsdelen användes (se Appendix A.1).

3.3.2 Hantering av target leakage

Variabeln sys_mod_count (antal uppdateringar av ärendet) identifierades som problematisk ur ett *target leakage*-perspektiv eftersom den hade ett starkt samband med handläggningstiden och riskerade att spegla processens utfall snarare än en oberoende förklarande faktor. Variabeln exkluderades därför, tillsammans med den därav härledda indikatorn för hög processaktivitet, så att modellerna inte använder information som är en följd av handläggningstiden.

På samma grunder exkluderades även variabeln made_sla eftersom den anger om SLA-målet uppfylldes och därmed innehåller information som är direkt kopplad till handläggningstidens utfall. Antal omfördelningar, antal återöppningar och tilldelad grupp avser värdena när ärendet avslutades. Analysen är därför retrospektiv: den undersöker samband och prediktionsförmåga i historiska data för avslutade ärenden, och modellerna är inte byggda för en bestämd tidpunkt för prediktion.

3.3.3 Log-transformering av målvariabeln

Handläggningstiden är kraftigt högersnedfördelad, där ett fåtal mycket långa ärenden driver upp medelvärdet. Eftersom detta kan få modellerna att systematiskt överskatta de typiska, kortare ärendena log-transformerades den beroende variabeln med log(1 + x) i ett andra steg, efter den första modelljämförelsen (se Appendix A.2).

3.3.4 Hyperparameteroptimering

För att förbättra de trädbaserade modellerna genomfördes hyperparameteroptimering med *RandomizedSearchCV* (se Appendix A.3). Modellerna tränades på den log-transformerade målvariabeln, och felet mättes i dagar efter att prediktionerna räknats tillbaka.
Femton slumpmässiga parameterkombinationer testades med femfaldig korsvalidering på träningsdatan och MAE som utvärderingsmått. Modellen med lägst korsvaliderat fel valdes och utvärderades därefter på testdatan.

3.3.5 Pipeline och tester

För att analysen ska kunna upprepas samlades dataförberedelse, kodning av kategoriska variabler, log-transformering, korsvalidering, modellval, utvärdering och omträning i en övergripande pipeline. Koden delades upp i filer för dataförberedelse, modellering, loggning samt en separat pipelinefil som kör hela flödet. Under körningen skrivs pipelinens steg och resultat till terminalen och till en loggfil med datum i namnet, så att varje körning kan följas i efterhand.

Grupperingen till de tio vanligaste värdena lärs in på träningsdatan och tillämpas därefter på testdatan, så att ingen information från testdatan påverkar förbehandlingen. Pipelinen kontrollerades med automatiska tester som bland annat säkerställer att variabler med *target leakage* inte används, att prediktionerna anges i dagar och att modellen med lägst korsvaliderat fel väljs (se Appendix A.4).

3.4 Modellutvärdering

Modellernas prestanda utvärderades med hjälp av MAE (Mean Absolute Error) och R^2 (förklaringsgrad). MAE användes för att mäta den genomsnittliga avvikelsen mellan predikterade och faktiska värden, vilket ger en direkt tolkning i dagar. R^2 användes för att bedöma i vilken utsträckning modellerna kan förklara variationen i handläggningstid.

I ett andra steg tränades modellerna på log-transformerad handläggningstid. Prediktionerna räknades tillbaka till dagar innan MAE och R^2 beräknades, så att resultaten är jämförbara med den naiva baseline-modellen.

Modellerna jämfördes med femfaldig korsvalidering på träningsdatan. Det ger en tillförlitlig bild av modellernas prestanda och stabilitet, och valet av modell beror inte på en enskild uppdelning av datan.

Utöver dessa mått analyserades residualer för att undersöka modellernas felbeteende, samt SHAP-värden för att tolka vilka variabler som hade störst påverkan på modellens prediktioner och i vilken riktning. Kombinationen av dessa metoder möjliggör en balanserad utvärdering av både modellernas noggrannhet, förklaringsförmåga och tolkningsbarhet.

4 Resultat och diskussion

Detta kapitel presenterar resultaten från analysen av handläggningstid i ärendehanteringsprocessen. Fokus ligger på att identifiera mönster, variationer och processrelaterade faktorer kopplade till handläggningstid samt att analysera modellernas förmåga att identifiera samband i datan.

4.1 KPI- och processanalys

För att få en övergripande förståelse för processens effektivitet sammanställdes centrala KPI:er relaterade till handläggningstid och processaktivitet (Tabell 1).

KPI-sammanställningen visar att den genomsnittliga handläggningstiden är betydligt högre än medianvärdet, vilket indikerar att ett mindre antal ärenden med mycket långa handläggningstider påverkar genomsnittet och bidrar till en skev fördelning.

Resultaten visar att 61,8 % av ärendena uppfyller SLA-målet. Andelen återöppnade ärenden är relativt låg (1,20 %), vilket kan indikera att majoriteten av ärendena löses utan behov av ytterligare hantering efter avslut.

KPI	Värde
Antal ärenden	23 362
Genomsnittlig handläggningstid (dagar)	7,42
Median handläggningstid (dagar)	0,92
SLA-uppfyllelse (%)	61,8
Andel återöppnade ärenden (%)	1,20
Genomsnittligt antal omfördelningar	1,00
Andel långdragna ärenden (%)	25,0

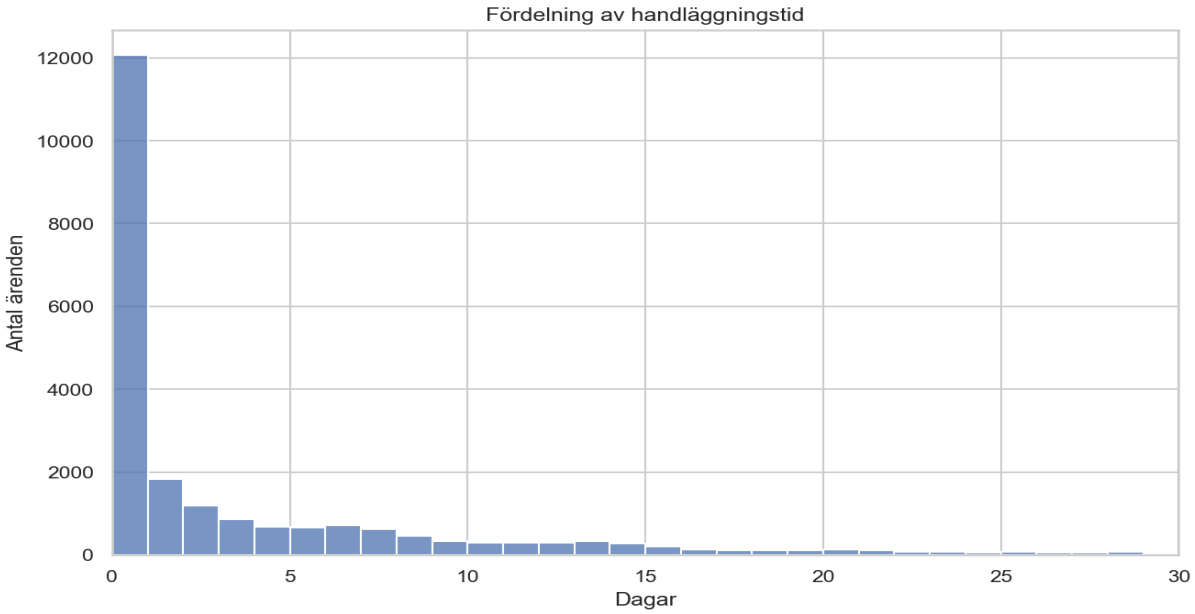
Tabell 1: Sammanställning av centrala KPI:er relaterade till handläggningstid och processaktivitet. Långdragna ärenden definieras som de 25 % av ärendena som har längst handläggningstid.

4.2 Övergripande analys av handläggningstid

Analysen visar att handläggningstiden uppvisar stor variation mellan olika ärenden. Fördelningen är tydligt snedfördelad, där majoriteten av ärendena hanteras inom en begränsad tidsram samtidigt som ett mindre antal ärenden har betydligt längre handläggningstid (Figur 1).

Resultaten indikerar att handläggningstid påverkas av flera underliggande faktorer och att mönstren inte kan förklaras av en enskild variabel. Förekomsten av ärenden med mycket långa handläggningstider kan tyda på skillnader i processkomplexitet, resursbehov eller variationer i hur ärenden hanteras genom processen.

Den stora variationen i handläggningstid indikerar även att problemet är komplext ur ett prediktivt perspektiv, då hög variation kan göra det svårare för modeller att identifiera tydliga och stabila samband.

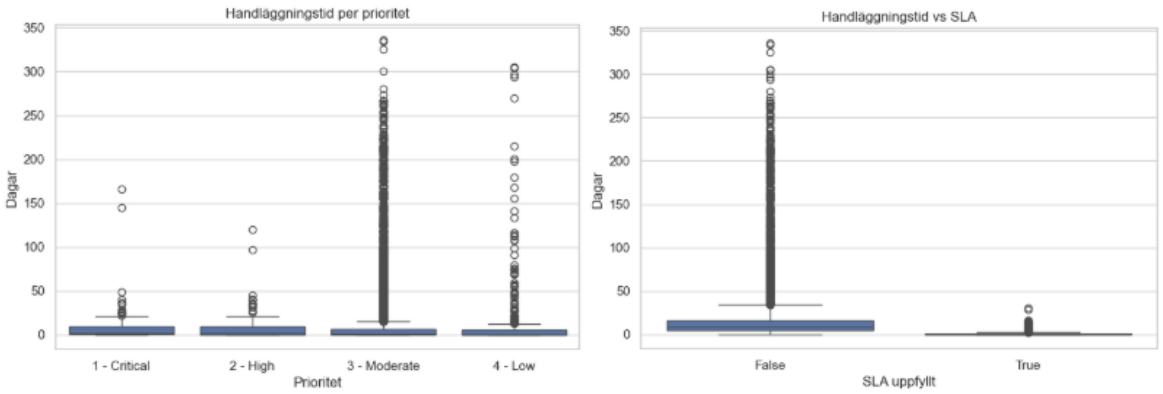


Figur 1: Fördelning av handläggningstid i dagar där majoriteten av ärendena uppvisar relativt kort handläggningstid. Axeln är begränsad till 30 dagar för läsbarhetens skull.

4.3 Processrelaterade faktorer

Analysen visar att vissa processrelaterade faktorer har tydligare samband med handläggningstid än andra. Framför allt observeras samband mellan handläggningstid och variabler kopplade till processaktivitet, omfördelningar och SLA-uppfyllelse.

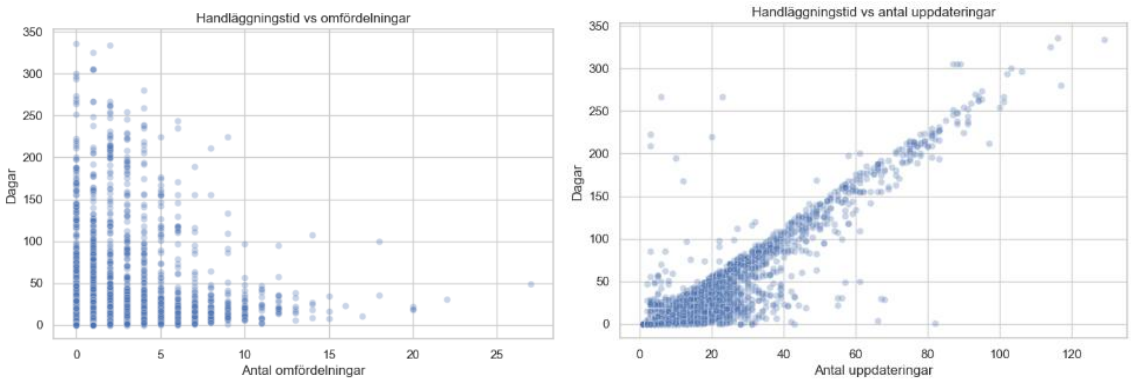
Vid analys av prioritet framgår att skillnaderna i handläggningstid mellan olika prioriteringsnivåer är relativt begränsade. Samtidigt förekommer stor variation inom varje prioriteringskategori, vilket indikerar att prioritet i sig inte fullt ut förklarar variationen i handläggningstid (Figur 2).



Figur 2: Fördelning av handläggningstid mellan olika prioriteringsnivåer samt handläggningstid för ärenden med och utan uppfyllt SLA.

Analysen av SLA-uppfyllelse visar mycket tydliga skillnader. Ärenden där SLA inte uppfylldes hade en genomsnittlig handläggningstid på 18,3 dagar, jämfört med 0,72 dagar för ärenden där SLA uppfylldes. Sambandet är dock delvis givet, eftersom SLA-uppfyllelse i sig avgörs av hur lång tid ärendet tar (Figur 2).

Analysen visar även samband mellan handläggningstid och processaktivitet. Ärenden med fler omfördelningar tenderar att ha längre handläggningstid, men sambandet är svagt (korrelation ≈ 0,21) och uppvisar stor variation, vilket indikerar att omfördelningar endast delvis förklarar skillnader i handläggningstid (Figur 3).



Figur 3: Samband mellan handläggningstid, antal omfördelningar och antal uppdateringar.

Ett mycket starkare samband observeras mellan antal uppdateringar och handläggningstid, med en korrelation på ≈ 0,90 (Figur 3). Ärenden med fler uppdateringar har längre handläggningstid, vilket kan tyda på att mer komplexa ärenden kräver fler aktiviteter. Sambandet är dock delvis givet, eftersom antalet uppdateringar ökar i takt med att ärendet pågår. Detta, liksom SLA-uppfyllelsen ovan, innebär att variablerna inte kan användas som förklarande variabler för prediktion.

4.4 Initial modellering

För att undersöka om handläggningstid kan predikteras jämfördes flera regressionsmodeller med olika grad av komplexitet, med en naiv baseline-modell som referens. Modellerna jämfördes med femfaldig korsvalidering på träningsdatan. Baseline-modellen, som alltid predikterar medianen, uppnådde ett MAE på 7,29 dagar (Tabell 2).

Modell	MAE	MAE (std)	R^2
Naiv baseline (median)	7,29	0,36	−0,09
Random Forest	7,88	0,23	0,17
Gradient Boosting	7,90	0,21	0,16
Linear Regression	8,54	0,18	0,13

Tabell 2: Modellernas prestanda i femfaldig korsvalidering på träningsdatan. MAE anges i dagar som medelvärde över de fem delmängderna, med standardavvikelse. R^2 är medelvärdet.

Samtliga tränade modeller presterade sämre än baseline-modellen mätt med MAE (7,88 till 8,54 dagar mot 7,29 dagar), trots en svagt positiv förklaringsgrad (R^2 mellan 0,13 och 0,17). Eftersom ingen modell slog baseline-modellen undersöktes orsakerna närmare i de följande avsnitten.

4.5 Log-transformering och hyperparameteroptimering

Handläggningstiden är kraftigt högersnedfördelad, vilket fick modellerna att systematiskt överskatta de typiska, kortare ärendena. Den beroende variabeln log-transformerades därför och modellerna korsvaliderades på nytt.

Random Forest (MAE 6,53 dagar) och Gradient Boosting (MAE 6,46 dagar) presterade då bättre än baseline-modellen (MAE 7,29 dagar).

Linjär regression fungerade däremot sämre, med ett MAE på 8,17 dagar och ett kraftigt negativt R^2 (−27,14). Modellen gav orimliga prediktioner när de räknades om från log-skala till dagar. Den lägsta var en negativ handläggningstid och den högsta över 15 000 dagar.

Hyperparameteroptimering med *RandomizedSearchCV* förbättrade de trädbaserade modellerna ytterligare. Modellerna jämfördes med korsvalidering på träningsdatan (Tabell 3). Gradient Boosting (optimerad) hade lägst fel och valdes, men skillnaden mot Random Forest (optimerad) är mycket liten.

Modell	CV-MAE (dagar)
Gradient Boosting (optimerad)	6,410
Random Forest (optimerad)	6,411
Gradient Boosting	6,463
Random Forest	6,526
Naiv baseline (median)	7,295
Linear Regression	8,166

Tabell 3: Korsvaliderat MAE i dagar för modellerna efter log-transformering. Gradient Boosting (optimerad) har lägst fel och valdes.

Den valda modellen utvärderades därefter på testdatan och uppnådde ett MAE på 6,54 dagar och ett R^2 på 0,06.

Förklaringsgraden är fortsatt låg, vilket innebär att modellen endast förklarar en liten del av variationen i handläggningstid. Som jämförelse uppnådde baseline-modellen ett MAE på 7,29 dagar i korsvalideringen. Resultaten tyder sammantaget på att de tillgängliga variablerna ger begränsad information om hur lång tid ett ärende kommer att ta.

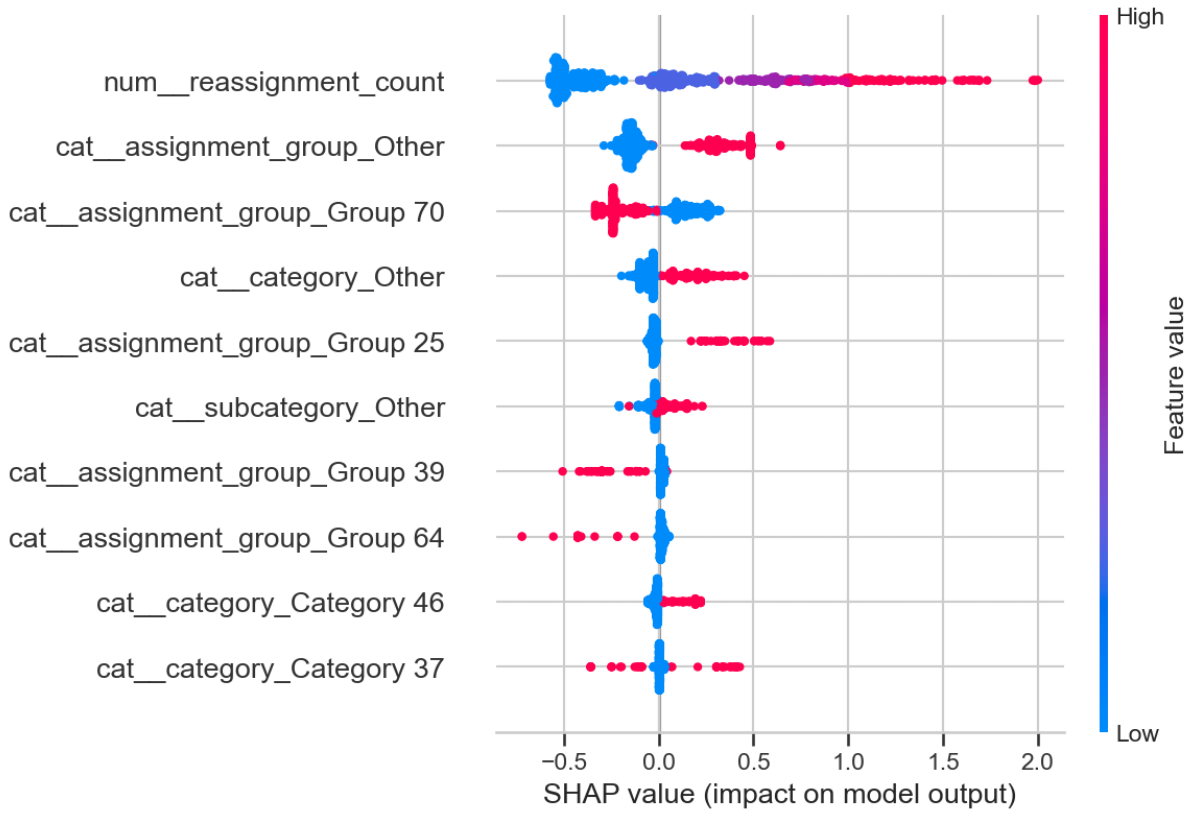
4.6 SHAP-analys och variabelbetydelse

För att få en djupare förståelse för vilka variabler som driver modellens prediktioner analyserades SHAP-värden för den valda modellen, Gradient Boosting (optimerad). Analysen gjordes på ett slumpmässigt urval av 1 000 ärenden ur träningsdatan. Eftersom modellen tränades på log-transformerad handläggningstid anges SHAP-värdena i log-skala.

Analysen visar att antal omfördelningar, **reassignment_count**, hade störst påverkan på modellens prediktioner, där höga värden konsekvent driver upp predikterad handläggningstid (Figur 4). Antalet omfördelningar ökar under ärendets gång och avser värdet när ärendet avslutades, vilket delvis kan förklara varför variabeln har så stor påverkan på modellens prediktioner.

Bland de övriga variablerna med störst betydelse återfinns framför allt tilldelad grupp samt vissa kategorier och underkategorier. Tilldelad grupp anger vilket team som hanterade ärendet, medan kategori och underkategori anger ärendets typ. Gruppen "Other" samlar de grupper som inte tillhör de tio vanligaste. Påverkan varierar mellan olika grupper och kategorier, där vissa är kopplade till längre och andra till kortare handläggningstid. Eftersom dessa variabler är anonymiserade i datasetet går det inte att tolka vad de olika grupperna och kategorierna representerar.

Prioritet och återöppnade ärenden finns inte bland de tio viktigaste variablerna. Att prioritet inte har större betydelse är i linje med resultaten från den explorativa analysen.

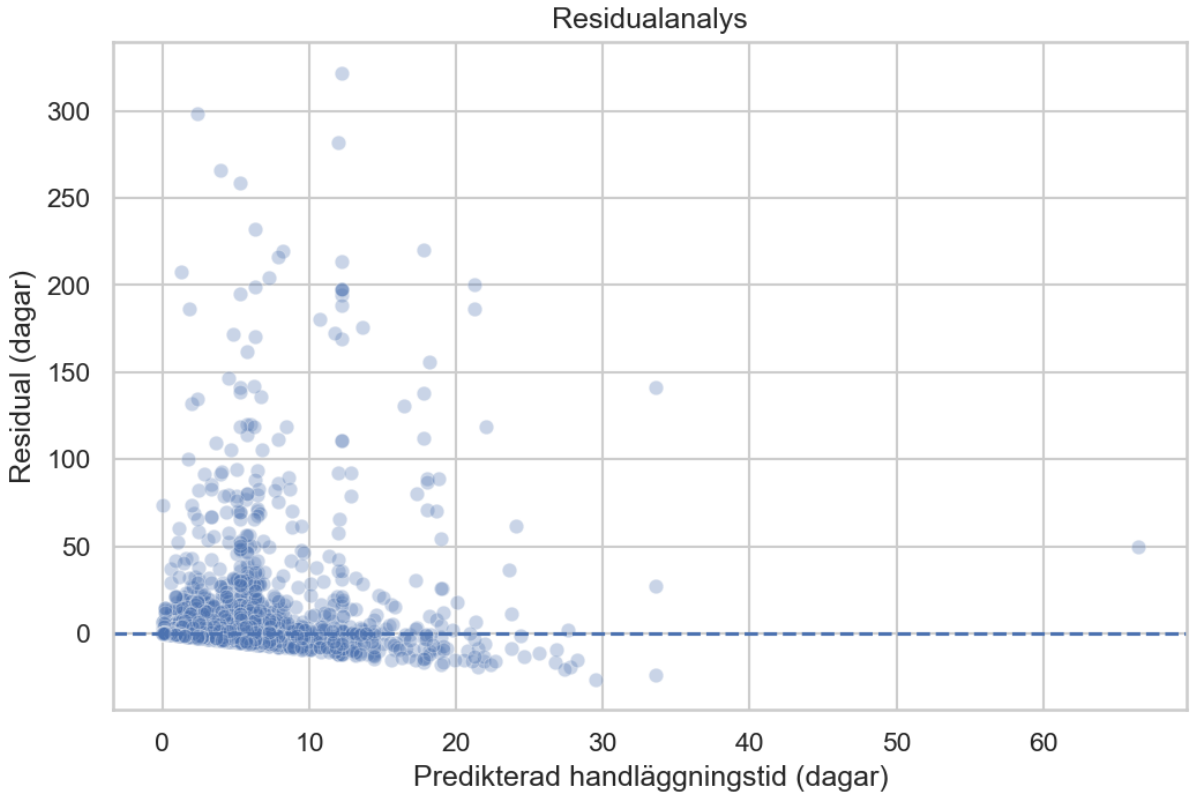


Figur 4: SHAP-analys för Gradient Boosting (optimerad) som visar variablernas påverkan på modellens prediktioner (log-skala), beräknad på ett urval av 1 000 ärenden.

4.7 Residualanalys

Residualanalysen, där residualen är faktiskt värde minus predikterat värde, visar att residualerna inte är symmetriskt fördelade kring noll. De flesta positiva avvikelserna är betydligt större än de negativa, särskilt för ärenden med lägre predikterade värden (Figur 5).

Det innebär att modellen systematiskt underskattar handläggningstiden för ärenden med mycket långa faktiska värden, och att den har svårt att fånga de mest extrema fallen trots log-transformeringen. Detta indikerar att en stor del av variationen i processen inte kan förklaras med de tillgängliga variablerna.



Figur 5: Residualanalys för den valda modellen på testdatan, som illustrerar variationen mellan modellens prediktioner och faktiska handläggningstider.

5 Slutsatser & Lärdomar

Analysen visar att handläggningstid har samband med flera processrelaterade faktorer och att vissa mönster kan identifieras i den tillgängliga datan. Antal omfördelningar visade ett tydligare samband med handläggningstid än exempelvis prioritet, vilket indikerar att processrelaterade faktorer kan vara mer informativa för att förstå variationen i handläggningstid än den initiala klassificeringen av ärenden.

Modelleringen visar samtidigt att handläggningstid kunde predikteras i begränsad utsträckning utifrån den tillgängliga datan. Den valda modellen, Gradient Boosting, uppnådde ett MAE på 6,54 dagar på testdatan och förklarade endast en liten del av variationen ($R^2 \approx 0,06$). Som jämförelse uppnådde den naiva baseline-modellen ett MAE på 7,29 dagar i korsvalideringen.

5.1 Datans betydelse

En central lärdom är att datans innehåll har stor betydelse för analysens resultat. Trots att datasetet innehåller flera processrelaterade variabler saknas information om faktorer som sannolikt påverkar handläggningstid, exempelvis ärendets komplexitet, arbetsbelastning och individuella arbetssätt. Detta begränsar modellernas möjlighet att fullt ut förklara variationen i handläggningstid och visar samtidigt vikten av relevant och kvalitativ processdata vid prediktiv analys.

5.2 Modellens praktiska användbarhet

Resultaten visar att mer avancerade modeller kan identifiera vissa mönster i datan, men att prediktionsförmågan fortfarande är begränsad. Modelleringen fungerar därför främst som ett analysstöd snarare än ett verktyg för exakta prognoser. Analysen visar även att prediktiv modellering kan användas för att identifiera vilka variabler som har störst betydelse för modellens prediktioner. Detta kan bidra till ökad förståelse för processer och potentiella ineffektiviteter i ärendehantering.

5.3 Sammanfattande reflektion

Projektet visar hur dataanalys och prediktiv modellering kan användas för att identifiera mönster, variationer och begränsningar i ärendehanteringsprocesser. Kombinationen av explorativ analys, sammanställningar av centrala nyckeltal och modellering gav en bredare förståelse för hur olika processrelaterade faktorer hänger samman med handläggningstid. Projektet visar också vikten av att kritiskt granska modellresultat och undvika variabler som speglar processens utfall (*target leakage*).

En pipeline utvecklades efter analysen, där dataförberedelse, kodning av variabler, log-transformering, korsvalidering, modellval och modellträning samlades och kontrollerades med automatiska tester. Detta gör analysen reproducerbar och visar vikten av att resultat går att återskapa och kontrollera.

6 Framtida arbete

Analysen visade att tillgängliga variabler endast förklarar en liten del av variationen i handläggningstid. Framtida arbete kan därför använda data med fler variabler, till exempel ärendets komplexitet, arbetsbelastning och tidpunkt för registrering, för att undersöka om prediktionerna kan förbättras. Mer avancerad *feature engineering* på befintliga variabler är ett annat alternativ som potentiellt kan förbättra modellernas prediktionsförmåga.

SHAP-analysen visade att tilldelad grupp, kategori och underkategori hade betydelse för prediktionerna, men eftersom variablerna är anonymiserade gick det inte att tolka vad grupperna och kategorierna representerar. Med data där de är identifierbara skulle man kunna undersöka vad som gör vissa grupper och typer av ärenden långsammare.

Ärenden som saknade lösningsdatum uteslöts eftersom handläggningstiden inte kunde beräknas för dem. Eftersom dessa ärenden kan innehålla information om långdragna handläggningsprocesser skulle framtida arbete kunna undersöka metoder som kan hantera ärenden som ännu inte avslutats, så att de kan ingå i analysen.

Modellen skulle också kunna förbättras genom att fler typer av modeller testas, till exempel andra ensemblemetoder, och genom en bredare hyperparameteroptimering.

Residualanalysen visade att de mest långdragna ärendena systematiskt underskattades. Framtida arbete kan därför undersöka alternativa angreppssätt, till exempel att klassificera om ett ärende riskerar att bli långdraget i stället för att prediktera antal dagar. Ett sådant angreppssätt skulle potentiellt kunna ge ett mer användbart beslutsunderlag än en prediktion av exakt antal dagar. En tidsbaserad uppdelning av datan skulle dessutom visa hur väl modellen fungerar på nyare ärenden.

Pipelinen skulle kunna byggas vidare så att den körs automatiskt. Varje körning skulle då träna om och välja modell på den senaste datan, logga resultaten och jämföra dem med tidigare körningar, så att försämrad prestanda upptäcks tidigt. Modellen skulle sedan kunna användas för att förutsäga handläggningstid för nya ärenden. Det kräver att den bara använder variabler som är kända när ärendet registreras, till exempel prioritet och kategori, och inte antal omfördelningar, som uppstår först under handläggningen.

Slutligen skulle resultaten kunna presenteras i en dashboard som löpande följer centrala nyckeltal och visar prediktioner, så att ärenden med risk för lång handläggningstid kan uppmärksammas tidigt.

Appendix A

A.1 Modellkonfiguration

```
# Dela upp i tränings- och testdata (80/20)
X_train, X_test, y_train, y_test = train_test_split(
    X,
    y,
    test_size=0.2,
    random_state=42,
)

# Definiera modeller
models = [
    ("Linear Regression", LinearRegression()),
    (
        "Random Forest",
        RandomForestRegressor(
            n_estimators=300,
            max_depth=5,
            random_state=42,
        ),
    ),
    (
        "Gradient Boosting",
        GradientBoostingRegressor(random_state=42),
    ),
]

# Naiv baseline: förutsäger alltid medianen
dummy = DummyRegressor(strategy="median")

# Femfaldig korsvalidering på träningsdata
cv_candidates = [("Naiv baseline (median)", dummy)] + models

cv_results = []

for name, model in cv_candidates:
    model_pipeline = Pipeline(
        steps=[
            ("group_categories", TopCategories(grouped_cols, top_n=10)),
            ("preprocessor", preprocessor),
            ("model", model),
        ]
    )

    scores = cross_validate(
        model_pipeline,
        X_train,
        y_train,
        cv=5,
        scoring={
            "mae": "neg_mean_absolute_error",
            "r2": "r2",
        },
    )

    cv_results.append(
        {
            "Modell": name,
            "MAE": -scores["test_mae"].mean(),
            "MAE (std)": scores["test_mae"].std(),
            "R²": scores["test_r2"].mean(),
        }
    )
```

A.2 Log-transformering

```python
# Log-transformera målvariabeln för att hantera snedfördelad handläggningstid
def with_log_target(model):
    """Träna på log1p(y) och räkna tillbaka prediktionerna till dagar med expm1."""
    return TransformedTargetRegressor(
        regressor=model,
        func=np.log1p,
        inverse_func=np.expm1,
    )


# Femfaldig korsvalidering med log-transformerad målvariabel
# MAE beräknas i dagar efter återtransformering
cv_results_log = []

for name, model in [("Naiv baseline (median, log)", dummy)] + models:

    # Förbehandling och modellträning inom korsvalideringen
    model_pipeline = Pipeline(
        steps=[
            ("group_categories", TopCategories(grouped_cols, top_n=10)),
            ("preprocessor", preprocessor),
            ("model", model),
        ]
    )

    scores = cross_validate(
        with_log_target(model_pipeline),
        X_train,
        y_train,
        cv=5,
        scoring={
            "mae": "neg_mean_absolute_error",
            "r2": "r2",
        },
    )

    # Samla resultaten för varje modell
    cv_results_log.append(
        {
            "Modell": name,
            "MAE": -scores["test_mae"].mean(),
            "MAE (std)": scores["test_mae"].std(),
            "R²": scores["test_r2"].mean(),
        }
    )
```

A.3 Hyperparameteroptimering

```
# Hyperparametrar att testa för Gradient Boosting
gb_param_dist = {
    "regressor__model__n_estimators": [100, 200, 300],
    "regressor__model__max_depth": [2, 3, 4, 5],
    "regressor__model__learning_rate": [0.01, 0.05, 0.1, 0.2],
    "regressor__model__min_samples_leaf": [1, 5, 10],
}


# Skapa pipeline med förbehandling och Gradient Boosting
gb_pipeline = Pipeline(
    steps=[
        ("group_categories", TopCategories(grouped_cols, top_n=10)),
        ("preprocessor", preprocessor),
        ("model", GradientBoostingRegressor(random_state=42)),
    ]
)

# Optimera med log-transformerad målvariabel
gb_search = RandomizedSearchCV(
    estimator=with_log_target(gb_pipeline),
    param_distributions=gb_param_dist,
    n_iter=15,
    cv=5,
    scoring="neg_mean_absolute_error",
    random_state=42,
    n_jobs=-1,
)

gb_search.fit(X_train, y_train)
```

A.4 Projektlänkar

GitHub-repo:
https://github.com/lencemajzovska/incident-handling-time

Källförteckning

Bergstra, J., & Bengio, Y. (2012). Random Search for Hyper-Parameter Optimization. *Journal of Machine Learning Research*, *13*, 281-305.

Géron, A. (2019). *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow* (2:a upplagan). O'Reilly Media.

Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems, 30*.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research, 12*, 2825-2830. Hämtad från https://jmlr.org/papers/v12/pedregosa11a.html

Shamiul Islam Shifat. (n.d.). *IT Incident Log Dataset*. Kaggle. Hämtad från https://www.kaggle.com/datasets/shamiulislamshifat/it-incident-log-dataset